

Atendefy

Plataforma SaaS Multi-Tenant de Chatbots para WhatsApp

Documento de Design — v1.0

Data: 04 de junho de 2026

Autor: Jose Silva

Status: **Aprovado**

Visão Geral

O **Atendefy** é uma plataforma SaaS multi-tenant que permite a pequenas e médias empresas implantarem chatbots inteligentes no WhatsApp sem contratar funcionários para atendimento 24h. O produto é comercializado como assinatura mensal com planos flexíveis, atendendo nichos como clínicas, imobiliárias, escritórios contábeis, advogados e oficinas.


Atributo	Valor
Modelo de negócio	SaaS multi-tenant
MVP	Chatbot + WhatsApp
Potencial de receita	R\$ 100 a R\$ 2.000/mês por cliente
Investimento inicial (infra)	~R\$ 41/mês
Stack principal	ASP.NET Core 8 + PostgreSQL + Redis


Seção 1 — Arquitetura Geral

Stack Principal

Componente	Tecnologia	Função
API	ASP.NET Core 8	Backend principal com todos os módulos
Frontend	React + Vite + TypeScript	Painel SPA do cliente (static build)
Banco de dados	PostgreSQL 16	Multi-schema por tenant
Cache / Fila	Redis 7	Sessões, fila de mensagens, rate limit
Reverse Proxy	Caddy	TLS automático (Let's Encrypt), roteamento
WhatsApp não-oficial	Evolution API (Docker)	Conexão via QR Code
WhatsApp oficial	Meta Cloud API	Webhook HTTP + Graph API
UI Components	shadcn/ui + TanStack Query	Frontend do painel

Diagrama de Infraestrutura





Multi-tenancy

Cada tenant recebe um schema PostgreSQL dedicado (**tenant_{id}**). A API resolve o tenant por subdomínio (*cliente.atendefy.com.br*) ou por API key no header *X-Tenant-Key*. Isolamento total de dados entre tenants.

Domínios

- atendefy.com.br → landing page / marketing
- app.atendefy.com.br → painel do cliente (SPA)
- api.atendefy.com.br → API backend

Seção 2 — Módulos da API

A API segue arquitetura **Vertical Slice** — cada módulo é uma pasta autossuficiente com seus próprios endpoints, serviços e modelos.

```
Atendefy.API/  
  ■■■ Modules/  
    ■ ■■■ Tenants/          ← cadastro, configuração, onboarding  
    ■ ■■■ Auth/             ← JWT, refresh token, permissões por tenant  
    ■ ■■■ WhatsApp/         ← abstração sobre Meta API + Evolution API  
    ■ ■■■ Chatbot/          ← sessões de conversa, contexto, histórico  
    ■ ■■■ AI/               ← abstração multi-provider (OpenAI, Anthropic, Gemini)  
    ■ ■■■ Billing/           ← planos, uso, faturas, webhooks de pagamento  
    ■ ■■■ Webhooks/         ← recebimento de eventos externos  
  ■■■ Infrastructure/  
    ■ ■■■ Database/         ← EF Core, migrations, tenant resolver  
    ■ ■■■ Cache/            ← Redis helpers  
    ■ ■■■ Messaging/        ← fila interna via Redis Streams  
  ■■■ SharedKernel/        ← Result pattern, domain events, base entities
```

Abstração WhatsApp Gateway

```
IWhatsAppProvider  
  ■■■ MetaCloudProvider    (oficial – webhook + send via HTTP/Graph API)  
  ■■■ EvolutionProvider    (não-oficial – QR Code, REST da Evolution API)
```


A troca de provider é configurada por tenant no banco. O restante do sistema não conhece qual provider está ativo.

Abstração AI Provider

```
IAIProvider  
  ■■■ OpenAIProvider       (GPT-4o, GPT-4o mini)  
  ■■■ AnthropicProvider    (Claude Haiku, Sonnet)  
  ■■■ GeminiProvider       (Gemini Flash, Pro)
```

Cada tenant configura: provider preferido + API key própria, ou consome do pool da plataforma com custo repassado na fatura.

Seção 3 — Fluxo de uma Conversa



Sessão de Conversa (Redis — TTL 30 min)

```
{
  "sessionId": "whatsapp:5511999999999",
  "tenantId": "tenant_abc123",
  "messages": [
    { "role": "user", "content": "Oi, qual o horário?" },
    { "role": "assistant", "content": "Olá! Atendemos de seg a sex..." }
  ],
  "expiresAt": "30 minutos após última mensagem"
}
```

Seção 4 — Modelo de Dados e Billing

Schema Público (plataforma)

```
public.tenants      (id, name, subdomain, status, plan_id, created_at)
public.plans        (id, name, price_monthly, price_setup, limits_json)
public.subscriptions (id, tenant_id, plan_id, status, billing_cycle)
public.invoices      (id, tenant_id, amount, status, due_date)
```

Schema por Tenant

```
tenant_{id}.whatsapp_accounts (id, provider, phone, config_json, status)
tenant_{id}.ai_configs        (id, provider, api_key_encrypted, model)
tenant_{id}.conversations      (id, contact_phone, started_at, message_count)
tenant_{id}.messages           (id, conversation_id, role, content, tokens_used, created_at)
tenant_{id}.usage_counters     (month, messages_sent, tokens_consumed, cost_usd)
```

Billing Flexível via limits_json

```
{
  "max_whatsapp_numbers": 3,
  "max_messages_month": 5000,
  "ai_pool": true,
  "setup_fee": 150000,
  "monthly_fee": 49900,
  "overage_per_message": 5
}
```

(valores em centavos)

Modelo de Cobrança	Configuração
Plano fixo mensal	monthly_fee fixo, overage = 0
Pay-as-you-go	monthly_fee = 0, overage_per_message > 0
Setup + mensalidade	setup_fee > 0 + monthly_fee > 0
Plano customizado	qualquer combinação acima

Gateways de Pagamento

Gateway	Métodos	Custo
Asaas	Boleto, Pix, Cartão (BR)	1,99% por transação
Stripe	Cartão internacional	2,9% + R\$1,50 por transação

Seção 5 — Infraestrutura e Custos

Docker Compose (VPS)

```
services:
  caddy:          # reverse proxy + TLS automático
  atendefy-api:   # ASP.NET Core 8
  atendefy-web:   # React SPA (servida pelo Caddy como static)
  postgres:       # PostgreSQL 16
  redis:          # Redis 7
  evolution-api:  # WhatsApp não-oficial
  uptime-kuma:    # monitoramento de disponibilidade
```

Plano de Crescimento — Hetzner Cloud

Fase	Servidor	vCPU	RAM	Disco	Custo/mês
MVP (0–50 tenants)	CAX21 (ARM)	2	4 GB	40 GB	~€5 (~R\$30)
Crescimento (50–200)	CAX31	4	8 GB	80 GB	~€15 (~R\$90)
Escala (200–500)	CAX41	8	16 GB	160 GB	~€30 (~R\$180)

Custos Operacionais Mensais — Fase MVP


Item	Custo/mês
VPS Hetzner CAX21	~R\$30
Domínio .com.br	~R\$5
Backup Hetzner (20% do VPS)	~R\$6
OpenAI API (pool plataforma)	Variável — repassado ao cliente
Evolution API	Grátis (self-hosted)
Asaas	1,99% por transação
Stripe	2,9% + R\$1,50 por transação
Total fixo	~R\$41/mês

Pipeline CI/CD

```
GitHub (gratuito)
├──
├── GitHub Actions
│   ├── push main → build + testes automatizados
│   └── tag v* → docker build → push ghcr.io → deploy SSH no VPS
```

Seção 6 — Painel do Cliente e Onboarding

Fluxo de Onboarding



Páginas do Painel do Cliente

Tela	Funcionalidade
Dashboard	Métricas: conversas hoje, mensagens, tokens usados
WhatsApp	Conectar/desconectar números, status da conexão
Chatbot	Editar prompt do sistema, testar conversa ao vivo
IA	Escolher provider, inserir API key ou usar pool
Conversas	Histórico completo de conversas e mensagens
Billing	Plano atual, uso do mês, histórico de faturas
Configurações	Dados da empresa, gerenciar usuários da conta

Painel Super Admin (operador do Atendefy)

Tela	Funcionalidade
Tenants	Listar, ver status, impersonar, bloquear/suspender
Planos	Criar/editar planos e limites via limits_json
Financeiro	MRR, inadimplência, próximas cobranças
Uso global	Consumo de IA, mensagens, custo real vs receita

Seção 7 — Segurança

Autenticação e Autorização

Mecanismo	Detalhe
JWT Access Token	Expiração: 15 minutos
JWT Refresh Token	Expiração: 7 dias
Roles por tenant	Owner, Admin, Viewer
Super Admin	IP allowlist + header especial
API Keys externas	Hash SHA-256 armazenado no banco

Proteção de Dados Sensíveis

Dado	Proteção
API keys de IA do cliente	AES-256 encrypted no banco
Senhas de usuário	bcrypt (cost factor 12)
Tokens WhatsApp (Evolution)	AES-256 encrypted at rest
Dados de conversa	Isolados por schema PostgreSQL

Proteções Operacionais

- Rate limiting por tenant via Redis (mensagens/minuto por plano)
- Webhook signature validation (HMAC-SHA256 Meta / token Evolution)
- Tenant suspenso automaticamente após 7 dias de inadimplência
- Soft delete — tenant recupera dados até 30 dias após cancelamento
- Logs estruturados com Serilog + Uptime Kuma para monitoramento

Roadmap Pós-MVP

Feature	Quando adicionar
Agendamento automático via WhatsApp	Após 20 clientes pagantes
Geração de propostas	Após validar demanda com clientes
Follow-up automático de leads	Após feature de agendamento
App mobile para admin	Após R\$10k MRR
Migração seletiva para microsserviços	Após 500 tenants ativos

Resumo das Decisões Arquiteturais

Decisão	Escolha	Justificativa
Modelo de produto	SaaS multi-tenant	Escala sem crescer equipe operacional
Arquitetura backend	Monolito Modular	Entrega rápida, fácil manutenção, evoluível
Multi-tenancy	Schema por tenant	Isolamento real de dados
Hosting	VPS Hetzner	~R\$30/mês vs centenas em cloud gerenciada
WhatsApp	Dual provider	Oficial (seguro) + não-oficial (sem burocracia)
IA	Multi-provider	Sem lock-in, cliente usa própria key ou pool
Billing	Flexível via JSON	Planos customizados sem mudar código
Pagamentos	Asaas + Stripe	Cobertura: Pix/boleto BR + cartão internacional
CI/CD	GitHub Actions + ghcr.io	Gratuito, integrado, suficiente para MVP

Atendefy — Documento de Design v1.0 — Confidencial